

Optimal Theory and Method

最优化理论与方法

翟春杰

杭州电子科技大学 自动化学院
科技馆512

Email: cjzhai@hdu.edu.cn



约束非线性优化方法

■ 直接法

- 在满足不等式约束的可行设计区域内直接求出问题的约束最优解
- 可行方向法

■ 间接法

- 将约束优化问题转化为一系列无约束优化问题来解的一种方法
- 惩罚函数法

■ 外点法

■ 内点法



目录

- 外点法 (考)
- 内点法 (考)



目录

- 外点法 (考)
- 内点法 (考)



■ 外点法

- 外点法的**基本思想**
- 外点法的**惩罚函数构造**
- 外点法的**特点**



■ 外点法

➤ 基本思想

考虑约束问题

$$\begin{aligned} \min & f(x) \\ \text{s. t } & g_i(x) \geq 0, \quad i=1,2,\cdots,m \\ & h_j(x) = 0, \quad j=1,2,\cdots,l \end{aligned}$$

其中 $f(x)$, $g_i(x)$, $h_j(x)$ 是 E^n 上的连续函数

由目标函数和约束函数组成辅助函数，把原来的约束问题转化为极小化辅助函数的无约束问题

- 在可行点辅助函数值等于原来的目标函数值
- 在不可行点，辅助函数值等于原来的目标函数值加上一个很大的正数



■ 外点法

➤ 惩罚函数的构造

对于等式约束问题

$$\begin{aligned} \min & f(x) \\ \text{s. t } & h_j(\mathbf{x}) = 0 \quad j=1,2,\cdots,l \end{aligned} \quad (13.1.2)$$

可定义辅助函数

$$F_1(x, \sigma) = f(x) + \sigma \sum_{j=1}^l h_j^2(\mathbf{x}) \quad (13.1.3)$$

参数 σ 是很大的正数

转化为无约束问题 $\min F_1(x, \sigma) \quad (13.1.4)$

- (13.1.4)的最优解必使得 $h_j(\mathbf{x})$ 接近零;
- 问题 (13.1.4) 的解即是问题 (13.1.2) 的近似解



■ 外点法

➤ 惩罚函数的构造

对于不等式约束问题

$$\begin{aligned} & \min f(x) \\ & \text{s. t } g_i(x) \geq 0 \quad i=1,2,\dots,m \quad (13.1.2) \end{aligned}$$

定义函数

$$F_2(x, \sigma) = f(x) + \sigma \sum_{i=1}^m [\max\{0, -g_i(x)\}]^2$$

σ 是很大的正数

$$\max\{0, -g_i(x)\} = \begin{cases} 0, & \text{当 } x \text{ 为可行点时} \\ -g_i(x), & \text{当 } x \text{ 不是可行点时} \end{cases}$$

转化为无约束问题 $\min F_2(x, \sigma)$

→ 求得原约束问题的近似解



■ 外点法

➤ 惩罚函数的构造

对于一般情形的约束优化问题

$$\min f(\mathbf{x})$$

$$\text{s. t } g_i(\mathbf{x}) \geq 0, \quad i=1,2,\cdots,m$$

$$h_j(\mathbf{x}) = 0, \quad j=1,2,\cdots,l$$

定义函数

$$F(\mathbf{x}, \sigma) = f(\mathbf{x}) + \sigma P(\mathbf{x})$$

其中 $P(\mathbf{x})$ 具有下列形式

$$P(\mathbf{x}) = \sum_{i=1}^m \phi(g_i(\mathbf{x})) + \sum_{j=1}^l \varphi(h_j(\mathbf{x}))$$

典型取法

$$\phi = [\max\{0, -g_i(\mathbf{x})\}]^\alpha$$

$$\varphi = |h_j(\mathbf{x})|^\beta$$

通常取 $\alpha = \beta = 2$



■ 外点法

➤ 惩罚函数的构造

这样，把一般约束优化问题转化为无约束优化问题

$$\min F(x, \sigma) = f(\mathbf{x}) + \sigma P(\mathbf{x})$$

其中 σ 是很大的正数， $P(\mathbf{x})$ 是连续函数

$\sigma P(\mathbf{x})$ 称为**惩罚项**

σ 称为**惩罚因子**

$F(x, \sigma)$ 称为**罚函数**

求解无约束优化问题能够得到一般约束优化问题的近似解，
而且 **σ 越大，近似解越好**



■ 外点法

➤ 惩罚函数的构造

用外点法求解规划问题

$$\begin{array}{ll}\min & x \\ \text{s. t} & \mathbf{x}-2 \geq 0\end{array}$$

解：惩罚项：

$$\mathbf{P}(\mathbf{x}) = [\max\{0, -g_i(x)\}]^2 = \begin{cases} 0, & \text{当 } x \geq 2 \\ (\mathbf{x}-2)^2, & \text{当 } x < 2 \end{cases}$$

罚函数：

$$F(x, \sigma) = \mathbf{x} + \sigma \mathbf{P}(\mathbf{x})$$



■ 外点法

➤ 惩罚函数的构造

求解下列无约束问题，求得原约束问题的近似解

$$\min \quad \mathbf{x} + \sigma \mathbf{P}(\mathbf{x})$$

解析方法解无约束问题

$$\frac{dF}{dx} = \begin{cases} 1, & \text{当 } x \geq 2 \\ 1 + 2\sigma(x-2), & \text{当 } x < 2 \end{cases}$$

$$\text{令 } \frac{dF}{dx} = 0, \quad \bar{x}_\sigma = 2 - \frac{1}{2\sigma}$$


显然， σ 越大， \bar{x}_σ 越接近（13.1.11）的最优解

$\sigma \rightarrow +\infty$ 时， $\bar{x}_\sigma \rightarrow \bar{x} = 2$



■ 外点法

➤ 惩罚函数的构造





■ 外点法

➤ 惩罚函数的构造

用外点法求解规划问题

$$\begin{aligned} \min \quad & f(x) \triangleq (x_1 - 1)^2 + x_2^2 \quad (13.1.11) \\ \text{s. t} \quad & g(x) = x_2 - 1 \geq 0 \end{aligned}$$

解：

罚函数：

$$\begin{aligned} F(x, \sigma) &= (x_1 - 1)^2 + x_2^2 + \sigma [\max\{0, -(x_2 - 1)\}]^2 \\ &= \begin{cases} (x_1 - 1)^2 + x_2^2, & \text{当 } x_2 \geq 1 \\ (x_1 - 1)^2 + x_2^2 + \sigma(x_2 - 1)^2, & \text{当 } x_2 < 1 \end{cases} \end{aligned}$$



■ 外点法

➤ 惩罚函数的构造

解析方法

$$\frac{dF}{dx_1} = 2(x_1 - 1) = 0$$

$$\frac{dF}{dx_2} = \begin{cases} 2x_2, & \text{当 } x_2 \geq 1 \\ 2x_2 + 2\sigma(x_2 - 1), & \text{当 } x_2 < 1 \end{cases} = 0$$

$$x_2 = \frac{\sigma}{1 + \sigma} \quad \bar{x} = \begin{bmatrix} 1 \\ \frac{\sigma}{1 + \sigma} \end{bmatrix}$$

$$\text{令 } \sigma \rightarrow +\infty \text{ 时, } \bar{x}_\sigma \rightarrow \bar{x} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$



■ 外点法

➤ 特点

- 无约束问题的最优解 \bar{x} ，往往不满足原来的约束条件，它是从可行域外部趋向 \bar{x} 的
- $F(x, \sigma)$ 也称为外罚函数，相应的最优化方法也称为外点法或外罚函数法
- 罚因子 σ 的选择十分重要
如果 σ 过大，增加计算上的困难
如果 σ 太小，罚函数的极小点远离约束问题的最优解



目录

- 外点法 (考)
- 内点法 (考)



■ 内点法

- 内点法的**基本思想**
- 内点法的**障碍函数构造**
- 内点法的**特点**



■ 内点法

➤ 基本思想

内点法在迭代中总是**从内点出发**，并保持在**可行域内部**进行搜索。

适用于下列**只有不等式约束**的问题：

$$\min f(\mathbf{x})$$

$$\text{s. t. } g_i(\mathbf{x}) \geq 0 \quad i=1,2,\cdots,m$$

$f(\mathbf{x}), g_i(\mathbf{x})$ 是 E^n 上的连续函数

将可行域记作 $S=\{\mathbf{x} \mid g_i(\mathbf{x}) \geq 0, i=1,2,\cdots,m\}$



■ 内点法

➤ 障碍函数

保持迭代点含于可行域内部的方法是定义**障碍函数**

$$G(\mathbf{x}, r) = f(\mathbf{x}) + rB(\mathbf{x})$$

其中 $B(\mathbf{x})$ 是连续函数，当点 \mathbf{x} 趋向可行域边界时， $B(\mathbf{x}) \rightarrow +\infty$

两种最重要的形式

$$B(\mathbf{x}) = \sum_{i=1}^m \frac{1}{g_i(\mathbf{x})}$$

倒数形式

$$B(\mathbf{x}) = -\sum_{i=1}^m \log g_i(\mathbf{x})$$

对数形式（常用）



■ 内点法

➤ 障碍函数

$$G(\mathbf{x}, r) = f(\mathbf{x}) + rB(\mathbf{x})$$

r 是**很小的正数**，当 \mathbf{x} 趋向**边界**时，函数 $G(\mathbf{x}, r) \rightarrow +\infty$ ；
否则，由于 r 很小，则函数 $G(\mathbf{x}, r)$ 的取值**近似 $f(\mathbf{x})$** 。

求解下列问题得到原优化问题的近似解：

$$\begin{array}{ll} \min & G(\mathbf{x}, r) \\ \text{s. t.} & \mathbf{x} \in \text{int}S \end{array}$$

由于 $B(\mathbf{x})$ 的存在，在可行域边界**形成“围墙”**，因此解 $\overline{x_r}$
必含于**可行域的内部**。

由于 $B(\mathbf{x})$ 的**阻挡作用**是自动实现的，因此从计算的观点
看，可当作**无约束问题来处理**



■ 内点法

➤ 障碍函数

$$B(\mathbf{x}) = \sum_{i=1}^m \frac{1}{g_i(\mathbf{x})}$$

倒数形式

$$B(\mathbf{x}) = -\sum_{i=1}^m \log g_i(\mathbf{x})$$

对数形式

用内点法求解规划问题

$$\begin{aligned} \min \quad & \frac{1}{12} (x_1 + 1)^3 + x_2 \\ \text{s. t} \quad & x_1 - 1 \geq 0 \\ & x_2 \geq 0 \end{aligned}$$

解： 罚函数：

$$G(\mathbf{x}, r_k) = \frac{1}{12} (x_1 + 1)^3 + x_2 + r_k \left(\frac{1}{x_1 - 1} + \frac{1}{x_2} \right)$$



■ 外点法

➤ 障碍函数

用解析法求解

$$\min G(\mathbf{x}, r_k)$$

$$\text{s. t. } \mathbf{x} \in S$$

$$\frac{dG}{dx_1} = \frac{1}{4} (x_1 + 1)^2 - \frac{r_k}{(x_1 - 1)^2} = 0$$

$$\frac{dG}{dx_2} = 1 - \frac{r_k}{x_2^2} = 0$$

$$\bar{\mathbf{x}}_{r_k} = (x_1, x_2) = \left(\sqrt{1 + 2\sqrt{r_k}}, \sqrt{r_k} \right)$$

$r_k \rightarrow 0$ 时, $\bar{\mathbf{x}}_{r_k} \rightarrow \bar{\mathbf{x}} = (1, 0)$, $\bar{\mathbf{x}}$ 是问题的最优解



■ 作业

413:

1(4)、 3(2)



目录

- Lagrange方法
- 起作用集方法



目录

- Lagrange方法
- 起作用集方法



■ Lagrange方法

- 面向什么规划问题
- Lagrange函数的构造
- Lagrange方法的最优解



■ Lagrange方法

➤ 面向二次规划

考虑二次规划问题

$$\begin{aligned} \min \quad & \frac{1}{2} x^T H x + c^T x \\ \text{s.t.} \quad & A x = b \end{aligned} \quad (14.1.1)$$

其中**H**是**n**阶对称矩阵，**A**是**m**×**n**矩阵， $x \in \mathbb{R}^n$ ，**b**是**m**维列向量



■ Lagrange方法

➤ Lagrange函数

下面推导用Lagrange乘子法求解二次规划问题的公式

定义Lagrange函数

$$L(x, \lambda) = \frac{1}{2}x^T Hx + c^T x - \lambda^T (Ax - b)$$

令 $\nabla_x L(x, \lambda) = 0, \nabla_\lambda L(x, \lambda) = 0$

得到方程组
$$\begin{aligned} Hx + c - A^T \lambda &= 0 \\ -Ax + b &= 0 \end{aligned}$$

将此方程组写成

$$\begin{bmatrix} H & -A^T \\ -A & 0 \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} -c \\ -b \end{bmatrix}$$

Lagrange矩阵



■ Lagrange方法

➤ Lagrange函数

设上述Lagrange矩阵可逆，则可以表示为

$$\begin{bmatrix} H & -A^T \\ -A & 0 \end{bmatrix}^{-1} = \begin{bmatrix} Q & -R^T \\ -R & S \end{bmatrix}$$

由式

$$\begin{bmatrix} H & -A^T \\ -A & 0 \end{bmatrix} \begin{bmatrix} Q & -R^T \\ -R & S \end{bmatrix} = I_{m+n}$$

推得

$$\begin{cases} HQ + A^T R = I_n \\ -HR^T - A^T S = 0_{m+n} \\ -AQ = 0_{m+n} \\ AR^T = I_m \end{cases}$$



■ Lagrange方法

➤ Lagrange方法的最优解

$$\begin{cases} HQ + A^T R = I_n \\ -HR^T - A^T S = 0_{m+n} \\ -AQ = 0_{m+n} \\ AR^T = I_m \end{cases}$$

假设逆矩阵 H^{-1} 存在，得到矩阵 Q, R, S 的表达式

$$\begin{cases} Q = H^{-1} - H^{-1}A^T(AH^{-1}A^T)^{-1}AH^{-1} & (14.1.4) \\ R = (AH^{-1}A^T)^{-1}AH^{-1} & (14.1.5) \end{cases}$$

Q, S 对称矩阵

$$\begin{cases} S = -(AH^{-1}A^T)^{-1} & (14.1.6) \end{cases}$$

$$\begin{bmatrix} H & -A^T \\ -A & 0 \end{bmatrix} \begin{bmatrix} x \\ \lambda \end{bmatrix} = \begin{bmatrix} -c \\ -b \end{bmatrix}$$

将上式等号两端乘以Lagrange矩阵的逆，则得到问题的解

$$\begin{cases} \bar{x} = -Qc + R^T b & (14.1.7) \end{cases}$$

$$\begin{cases} \bar{\lambda} = Rc - Sb & (14.1.8) \end{cases}$$



■ Lagrange方法

➤ Lagrange方法的最优解

$$\begin{cases} \bar{\mathbf{x}} = -\mathbf{Q}\mathbf{c} + \mathbf{R}^T\mathbf{b} & (14.1.7) \\ \bar{\boldsymbol{\lambda}} = \mathbf{R}\mathbf{c} - \mathbf{S}\mathbf{b} & (14.1.8) \end{cases}$$

$\bar{\mathbf{x}}$ 和 $\bar{\boldsymbol{\lambda}}$ 的另一种表达式:

设 $\mathbf{x}^{(k)}$ 是任一可行解, 即 $\mathbf{x}^{(k)}$ 满足 $\mathbf{A}\mathbf{x}^{(k)} = \mathbf{b}$. 在此点目标函数的梯度

$$\mathbf{g}_k = \nabla f(\mathbf{x}^{(k)}) = \mathbf{H}\mathbf{x}^{(k)} + \mathbf{c}$$

利用 $\mathbf{x}^{(k)}$ 和 \mathbf{g}_k , 可将(14.1.7)和(14.1.8)改写成

$$\begin{cases} \bar{\mathbf{x}} = \mathbf{x}^{(k)} - \mathbf{Q}\mathbf{g}_k & (14.1.9) \\ \bar{\boldsymbol{\lambda}} = \mathbf{R}\mathbf{g}_k & (14.1.10) \end{cases}$$



■ Lagrange方法

➤ 例子

$$\begin{aligned} \min \quad & x_1^2 + 2x_2^2 + x_3^2 - 2x_1x_2 + x_3 \\ \text{s.t.} \quad & x_1 + x_2 + x_3 = 4 \\ & 2x_1 - x_2 + x_3 = 2 \end{aligned}$$

解： 易知

$$H = \begin{bmatrix} 2 & -2 & 0 \\ -2 & 4 & 0 \\ 0 & 0 & 2 \end{bmatrix}, c = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, A = \begin{bmatrix} 1 & 1 & 1 \\ 2 & -1 & 1 \end{bmatrix}, b = \begin{bmatrix} 4 \\ 2 \end{bmatrix},$$

$$H \text{ 的逆矩阵 } H^{-1} = \begin{bmatrix} 1 & \frac{1}{2} & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 \\ 0 & 0 & \frac{1}{2} \end{bmatrix}$$

$$\begin{aligned} \min \quad & \frac{1}{2} x^T H x + c^T x \\ \text{s.t.} \quad & Ax = b \end{aligned}$$



■ Lagrange方法

➤ 例子

$$\begin{cases} \bar{x} = -Qc + R^T b \\ \bar{\lambda} = Rc - Sb \end{cases}$$

由 (14.1.4) 至 (14.1.6) 得

$$Q = \frac{4}{11} \begin{bmatrix} \frac{1}{2} & \frac{1}{4} & -\frac{3}{4} \\ \frac{1}{4} & \frac{1}{8} & -\frac{3}{8} \\ -\frac{3}{4} & -\frac{3}{8} & \frac{9}{8} \end{bmatrix} \quad R = \frac{4}{11} \begin{bmatrix} \frac{3}{4} & \frac{7}{4} & \frac{1}{4} \\ \frac{3}{4} & -1 & \frac{1}{4} \end{bmatrix} \quad S = -\frac{4}{11} \begin{bmatrix} 3 & -\frac{5}{2} \\ -\frac{5}{2} & 3 \end{bmatrix}$$

把Q, R代入 (14.1.7), 得到问题的最优解

$$\bar{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} \frac{21}{11} \\ \frac{43}{22} \\ \frac{3}{22} \end{bmatrix}$$



■ Lagrange方法

➤ 例子

$$Q = \frac{4}{11} \begin{bmatrix} \frac{1}{2} & \frac{1}{4} & -\frac{3}{4} \\ \frac{1}{4} & \frac{1}{8} & -\frac{3}{8} \\ -\frac{3}{4} & -\frac{3}{8} & \frac{9}{8} \end{bmatrix}, \quad R = \frac{4}{11} \begin{bmatrix} \frac{3}{4} & \frac{7}{4} & \frac{1}{4} \\ \frac{3}{4} & -1 & \frac{1}{4} \\ \frac{3}{4} & \frac{1}{4} & \frac{1}{4} \end{bmatrix}$$

$$H = \begin{bmatrix} 2 & -2 & 0 \\ -2 & 4 & 0 \\ 0 & 0 & 2 \end{bmatrix}, \quad c = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$\bar{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} \frac{21}{11} \\ \frac{43}{22} \\ \frac{3}{22} \end{bmatrix}$$

$$\begin{cases} \bar{x} = x^{(k)} - Qg_k \\ \bar{\lambda} = Rg_k \\ g_k = \nabla f(x^{(k)}) = Hx^{(k)} + c \end{cases}$$



目录

- Lagrange方法
- 起作用集方法



■ 起作用集方法

- 面向什么**规划问题**
- 起作用集方法的**基本思想**
- 起作用集方法的**计算步骤**



■ 起作用集方法

➤ 面向的规划问题

考虑具有不等式约束二次规划问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) \stackrel{\text{def}}{=} \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ \text{s. t} \quad & \mathbf{A} \mathbf{x} \geq \mathbf{b} \end{aligned} \quad (14.2.1)$$

其中 \mathbf{H} 是 n 阶对称矩阵, \mathbf{c} 是 n 维列向量, \mathbf{A} 是 $m \times n$ 矩阵, \mathbf{A} 的秩为 m , \mathbf{b} 是 m 维列向量, $\mathbf{x} \in \mathbb{R}^n$.



■ 起作用集方法

➤ 基本思想

由于不等式约束的出现，不能直接使用消元法和Lagrange方法求解，解决这个问题策略之一，是用起作用集方法将它转化为求解等式约束问题。

基本思路：

在每次迭代中，以已知的可行点为起点，把在该点起作用约束作为等式约束，在此约束下极小化目标函数 $f(\mathbf{x})$ ，而其余的约束暂且不管，求得新的比较好的可行点后，再重复以上做法。



■ 起作用集方法

➤ 搜索方向和步长

设在第 k 次迭代中，已知可行点 $\mathbf{x}^{(k)}$ ，在该点起作用约束指标集用 $I^{(k)}$ 表示，这时需要求解等式约束问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s. t} \quad & \mathbf{a}^{(i)}\mathbf{x} = \mathbf{b}_i, \quad i \in I^{(k)} \end{aligned} \quad (14.2.2)$$

其中 $\mathbf{a}^{(i)}$ 是矩阵 \mathbf{A} 的第 i 行。



■ 起作用集方法

➤ 搜索方向和步长

$$\begin{aligned} \min & f(\mathbf{x}) \\ \text{s. t} & a^{(i)} \mathbf{x} = b_i, \quad i \in I^{(k)} \end{aligned}$$

为方便起见，现将坐标原点移至 $\mathbf{x}^{(k)}$ ，令

$$\boldsymbol{\delta} = \mathbf{x} - \mathbf{x}^{(k)},$$

$$\begin{aligned} \text{则 } f(\mathbf{x}) &= \frac{1}{2} (\boldsymbol{\delta} + \mathbf{x}^{(k)})^T \mathbf{H} (\boldsymbol{\delta} + \mathbf{x}^{(k)}) + \mathbf{c}^T (\boldsymbol{\delta} + \mathbf{x}^{(k)}) \\ &= \frac{1}{2} \boldsymbol{\delta}^T \mathbf{H} \boldsymbol{\delta} + (\mathbf{H} \mathbf{x}^{(k)})^T \boldsymbol{\delta} + \frac{1}{2} \mathbf{x}^{(k)T} \mathbf{H} \mathbf{x}^{(k)} + \mathbf{c}^T \boldsymbol{\delta} + \mathbf{c}^T \mathbf{x}^{(k)} \\ &= \frac{1}{2} \boldsymbol{\delta}^T \mathbf{H} \boldsymbol{\delta} + \nabla f(\mathbf{x}^{(k)})^T \boldsymbol{\delta} + f(\mathbf{x}^{(k)}) \end{aligned} \quad (14.2.3)$$

于是问题 (14.2.2) 转化成求校正量 $\boldsymbol{\delta}^{(k)}$ 的问题

$$\begin{aligned} \min & \frac{1}{2} \boldsymbol{\delta}^T \mathbf{H} \boldsymbol{\delta} + \nabla f(\mathbf{x}^{(k)})^T \boldsymbol{\delta} \\ \text{s. t} & a^{(i)} \boldsymbol{\delta} = 0, \quad i \in I^{(k)} \end{aligned} \quad (14.2.4)$$

求出最优解 $\boldsymbol{\delta}^{(k)}$



■ 起作用集方法

➤ 搜索方向和步长

如果 $x^{(k)} + \delta^{(k)}$ 是可行点, 且 $\delta^{(k)} \neq 0$, 则在第 $k+1$ 次迭代中, 已知点取作

$$x^{(k+1)} = x^{(k)} + \delta^{(k)}$$

如果 $x^{(k)} + \delta^{(k)}$ 不是可行点, 则令方向 $d^{(k)} = \delta^{(k)}$, 并沿 $d^{(k)}$ 搜索, 令 $x = x^{(k)} + \alpha d^{(k)}$

确定沿 $d^{(k)}$ 方向的步长 α_k , 根据保持可行性的要求, α_k 的取值应使得对于每个 $i \in I^{(k)}$ 成立

$$a^{(i)}(x^{(k)} + \alpha d^{(k)}) \geq b_i \quad (14.2.5)$$



■ 起作用集方法

➤ 搜索方向和步长

$$a^{(i)}(x^{(k)} + \alpha d^{(k)}) \geq b_i$$

由于 $x^{(k)}$ 是可行点, $a^i x^{(k)} \geq b_i$

当 $a^i d^{(k)} \geq 0$ 时, 对任意的非负数 α_k , (14.2.5) 总成立;

当 $a^i d^{(k)} < 0$ 时, 只要取正数

$$\alpha_k \leq \min \left\{ \frac{b_i - a^i x^{(k)}}{a^i d^{(k)}} \mid i \notin I^{(k)}, a^i d^{(k)} < 0 \right\},$$

对于每个 $i \notin I^{(k)}$, (14.2.5) 成立。

记 $\hat{\alpha}_k = \min \left\{ \frac{b_i - a^i x^{(k)}}{a^i d^{(k)}} \mid i \notin I^{(k)}, a^i d^{(k)} < 0 \right\}$



■ 起作用集方法

➤ 搜索方向和步长

$$a^{(i)}(x^{(k)} + \alpha d^{(k)}) \geq b_i$$

综上，为在第k次迭代中得到较好可行点，应取

$$\alpha_k = \min \{1, \hat{\alpha}_k\} \quad (14.2.6)$$

于是

$$x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}$$

如果

$$\alpha_k = \frac{b_p - a^p x^{(k)}}{a^p d^{(k)}} < 1 \quad (14.2.7)$$

则在点 $x^{(k+1)}$ ，有 $a^p x^{(k+1)} = a^p (x^{(k)} + \alpha_k d^{(k)}) = b_p$

因此，在 $x^{(k+1)}$ 处， $a^p x \geq b_p$ 为起作用约束。这时，把指标 p 加入 $I^{(k)}$ ，得到在 $x^{(k+1)}$ 处的起作用约束指标集 $I^{(k+1)}$



■ 起作用集方法

➤ 迭代终止条件

$$\begin{array}{ll} \min & f(\mathbf{x}) \\ \text{s. t} & a^{(i)} \mathbf{x} = b_i, \quad i \in I^{(k)} \end{array}$$

如果 $\delta^{(k)} = 0$ ，则 $x^{(k)}$ 是问题14.2.2的最优解。这时应判断 $x^{(k)}$ 是否为原约束问题的最优解：

为此，需计算起作用约束的乘子 $\lambda_i^{(k)} (i \in I^{(k)})$ 。若 $\lambda_i^{(k)} \geq 0$ ，则点 $x^{(k)}$ 是问题的K-T点，也是最优解。

如果存在 $q \in I^{(k)}$ ，使得 $\lambda_q^{(k)} < 0$ ，则 $x^{(k)}$ 不可能是最优解。

当 $\lambda_q^{(k)} < 0$ 时，把下标 q 从 $I^{(k)}$ 中删除。如果有几个乘子同时为负数，令 $\lambda_q^{(k)} = \min \{ \lambda_i^{(k)} \mid i \in I^{(k)} \}$

将对应 $\lambda_q^{(k)}$ 的约束从起作用约束集中去掉，再解转化问题



■ 起作用集方法

➤ 计算步骤

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

(1). 给定初始可行解 $x^{(1)}$, 相应的起作用约束指标集为 $I^{(k)}$, 置 $k=1$ 。

(2). 求解问题 (14.2.4), 设其最优解为 $\delta^{(k)}$, 若 $\delta^{(k)}=0$, 则进行步骤(5); 否则, 进行步骤(3)。

(3). 令 $d^{(k)} = \delta^{(k)}$, 由 (14.2.6) 确定 α_k , 令

$$x^{(k+1)} = x^{(k)} + \alpha_k d^{(k)}$$

计算 $\nabla f(x^{(k+1)})$

(4) 若 $\alpha_k < 1$, 则置 $I^{(k+1)} = I^{(k)} \cup \{p\}$, $k := k+1$, 返回步骤 (2); 若 $\alpha_k = 1$, 记点 $x^{(k+1)}$ 处起作用约束指标集为 $I^{(k+1)}$, 置 $k := k+1$, 进行步骤 (5)。

(5) 用 (14.1.10) 计算对应起作用约束的Lagrange乘子 $\lambda^{(k)}$, 设 $\lambda_q^{(k)} = \min \{ \lambda_i^{(k)} \mid i \in I^{(k)} \}$, 若 $\lambda_q^{(k)} \geq 0$, 则停止计算, 得到最优解 $x^{(k)}$; 否则, 从 $I^{(k)}$ 中删除 q , 返回步骤(2)



■ 起作用集方法

➤ 例子

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

用起作用集方法求解下列二次规划问题：

$$\begin{aligned} \min \quad & f(x) \stackrel{\text{def}}{=} x_1^2 - x_1 x_2 + 2x_2^2 - x_1 - 10x_2 \\ \text{s. t} \quad & -3x_1 - 2x_2 \geq -6 \\ & x_1, x_2 \geq 0 \end{aligned}$$

解：目标函数 $f(x)$ 写成

$$f(x) = \frac{1}{2} (x_1, x_2) \begin{bmatrix} 2 & -1 \\ -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + (-1, -10) \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

由此可知

$$H = \begin{bmatrix} 2 & -1 \\ -1 & 4 \end{bmatrix}, \quad c = \begin{bmatrix} -1 \\ -10 \end{bmatrix}$$



■ 起作用集方法

➤ 例子

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

取初始可行点 $x^{(1)} = (0, 0)^T$, 在点 $x^{(1)}$, 起作用指标集 $I^{(1)} = \{2, 3\}$, 求解相应的转化问题

$$\min f(x) \stackrel{\text{def}}{=} \delta_1^2 - \delta_1 \delta_2 + 2\delta_2^2 - \delta_1 - 10\delta_2$$

$$\text{s. t } \delta_1 = 0$$

$$\delta_2 = 0$$

$$\text{得解 } \delta^{(1)} = (0, 0)^T$$

因此 $x^{(1)}$ 是相应转化问题的最优解, 计算Lagrange乘子, 由 $I^{(1)} = \{2, 3\}$ 知

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$g_k = \nabla f(x^{(k)}) = Hx^{(k)} + c$$

$$R = (AH^{-1}A^T)^{-1}AH^{-1}$$

$$\bar{\lambda} = Rg_k$$

算得乘子 $\lambda_2^{(1)} = -1, \lambda_3^{(1)} = -10$, $x^{(1)}$ 不是例题的最优解。



■ 起作用集方法

➤ 例子

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t.} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

将 $\lambda_3^{(1)}$ 对应的约束，即原来问题的第3个约束，从起作用约束集中去掉，置 $I^{(1)} = \{2\}$ ，再解相应的转化问题

$$\begin{aligned} \min \quad & f(x) \stackrel{\text{def}}{=} \delta_1^2 - \delta_1 \delta_2 + 2\delta_2^2 - \delta_1 - 10\delta_2 \\ \text{s. t.} \quad & \delta_1 = 0 \end{aligned}$$

得解 $\delta^{(1)} = (0, \frac{5}{2})^T$ 。

由于 $\delta^{(1)} \neq 0$ ，需要计算 α_1 。由于 $\alpha_1 = \min \{1, \frac{6}{5}\} = 1$

令 $x^{(2)} = x^{(1)} + \alpha_1 \delta^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 1 \cdot \begin{bmatrix} 0 \\ \frac{5}{2} \end{bmatrix} = \begin{bmatrix} 0 \\ \frac{5}{2} \end{bmatrix}$ ，算出 $\nabla f(x^{(2)}) = (-\frac{7}{2}, 0)^T$



■ 起作用集方法

➤ 例子

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

由于 $\alpha_1=1$ ，置 $I^{(2)}=\{2\}$ ，在点 $x^{(2)}$ 处，计算相应的Lagrange乘子。

此时 $A = (1, 0)$, $b = 0$

算得 $\lambda_2^{(2)} = -\frac{7}{2}$ ，因此 $x^{(2)}$ 不是问题的最优解。

将指标2从 $I^{(2)}$ 中剔除，于是 $I^{(2)}=\phi$ ，再解相应的转化问题

$$\min \quad \delta_1^2 - \delta_1 \delta_2 + 2\delta_2^2 - \frac{7}{2} \delta_1$$

得解 $\delta^{(2)} = (2, \frac{1}{2})^T$ 。

由于 $\delta^{(2)} \neq 0$ ，需要计算 α_2 。由 (14.2.6)，有

$$\alpha_2 = \min \{1, \frac{1}{7}\} = \frac{1}{7}$$



■ 起作用集方法

➤ 例子

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

$$\text{令 } x^{(3)} = x^{(2)} + \alpha_2 \delta^{(2)} = \begin{bmatrix} 0 \\ 5 \\ 2 \end{bmatrix} + \frac{1}{7} \cdot \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} \frac{2}{7} \\ \frac{18}{7} \\ 2 \end{bmatrix}$$

$$\text{算出 } \nabla f(x^{(3)}) = (-3, 0)^T$$

在点 $x^{(3)}$ ，第1个约束起作用约束，这时 $I^{(3)} = \{1\}$ ，解相应的转化问题

$$\begin{aligned} \min \quad & \delta_1^2 - \delta_1 \delta_2 + 2\delta_2^2 - \frac{7}{2} \delta_1 \\ \text{s. t} \quad & -3\delta_1 - 2\delta_2 = 0 \end{aligned}$$

得解 $\delta^{(3)} = (\frac{3}{14}, -\frac{9}{28})^T$ 。计算 α_3 ：

$$\alpha_3 = \min \{1, 8\} = 1$$



■ 起作用集方法

➤ 例子

$$\begin{aligned} \min \quad & \frac{1}{2} \delta^T H \delta + \nabla f(x^{(k)})^T \delta \\ \text{s. t} \quad & a^{(i)} \delta = 0, \quad i \in I^{(k)} \end{aligned}$$

$$\text{令 } x^{(4)} = x^{(3)} + \alpha_3 \delta^{(3)} = \begin{bmatrix} \frac{2}{7} \\ \frac{18}{7} \end{bmatrix} + 1 \cdot \begin{bmatrix} \frac{3}{14} \\ -\frac{9}{28} \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{9}{4} \end{bmatrix}$$

$$\text{算出 } \nabla f(x^{(4)}) = \left(-\frac{9}{4}, -\frac{3}{2}\right)^T$$

在点 $x^{(4)}$, $I^{(4)} = \{1\}$, 计算相应的Lagrange乘子, 得到 $\lambda_1^{(4)} = \frac{3}{4}$, 点 $x^{(4)} = \left(\frac{1}{2}, \frac{9}{4}\right)^T$ 是所求的最优解。