

Optimal Theory and Method

最优化理论与方法



翟春杰

杭州电子科技大学 自动化学院
科技馆512

Email: cjzhai@hdu.edu.cn



回顾

■ 无约束优化问题

$$\min_{x \in R^n} f(x)$$

■ 迭代算法的基本思想

- 给一个迭代的初始点 $x^{(0)}$,
- 根据迭代公式 $x^{(k+1)} = x^{(k)} + \lambda_k d_k$ 进行迭代,
- 迭代截止条件

若 $f(x)$ 导数存在, 截止条件一般为: $\|\nabla f(x^{(k)})\| \leq \varepsilon$

其它情况, 截止条件可为 $\|x^{(k+1)} - x^{(k)}\| \leq \varepsilon$



回顾

■ 下降方向

$$\nabla f(x^{(k)})^T d^{(k)} < 0$$

$$x^{(k+1)} = x^{(k)} + \lambda_k d_k$$

■ 最优性的必要条件

点 $x^{(k)}$ 为**目标函数** $f(x)$ 局部最优点的必要条件：

点 $x^{(k)}$ 处**不存在可行下降方向**



目录

- 最速下降法 (考)
- 牛顿法 (考)
- 共轭梯度法 (考)
- 拟牛顿法
- 信赖域法
- 最小二乘法



目录

- **最速下降法 (考)**
- **牛顿法 (考)**
- **共轭梯度法 (考)**
- **拟牛顿法**
- **信赖域法**
- **最小二乘法**



■ 最速下降法

- 最速下降法面向哪类优化问题
- 什么是**最速下降方向**
- 最速下降法的**步长**
- 最速下降法的**步骤**



■ 最速下降法

➤ 适用于的优化问题

无约束优化问题：

$$\min f(\mathbf{x}), \quad \mathbf{x} \in \mathbf{R}^n,$$

其中， $f(x)$ 具有一阶连续偏导数

适用的优化问题：

- 无约束
- 目标函数一阶连续可导



■ 最速下降法

➤ 最速下降方向

1874年法国著名数学家Cauchy提出： **负梯度方向就是最速下降方向** **Why?**

$$f(x^{(k)} + \lambda_k d_k) - f(x^{(k)}) = \lambda_k \nabla f(x^{(k)})^T d^{(k)} + \|\lambda_k d_k\| \alpha(x^{(k)}, \lambda_k d_k) < 0$$

$$\nabla f(x^{(k)})^T d^{(k)} = \|\nabla f(x^{(k)})\| \|d^{(k)}\| \cos \theta$$

$$\text{当 } \theta = \pi, \quad \nabla f(x^{(k)})^T d^{(k)} = -\|\nabla f(x^{(k)})\| \|d^{(k)}\|$$

此时 $\nabla f(x^{(k)})$ 与 $d^{(k)}$ 方向相反

$$d^{(k)} = k \cdot (-\nabla f(x^{(k)}))$$

通常情况下 $k = 1$, $d^{(k)} = -\nabla f(x^{(k)})$



■ 最速下降法

➤ 最速下降法的最优步长

迭代算法的迭代公式：

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

最速下降法的迭代公式：

$$x^{(k+1)} = x^{(k)} - \lambda_k \nabla f(x^{(k)})$$

如何确定最优步长 λ_k ：

$$\lambda_k = \min_{\lambda > 0} f(x^{(k)} - \lambda \nabla f(x^{(k)}))$$



■ 最速下降法

➤ 最速下降法的步骤

(1) 给定初点 $x^{(1)} \in R^n$, 允许误差 $\varepsilon > 0$, 置 $k = 1$;

(2) 计算搜索方向 $d^{(k)} = -\nabla f(x^{(k)})$;

(3) 若 $\|d^{(k)}\| \leq \varepsilon$, 停止计算; 否则, 从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 进行一维搜索, 确定最优 λ_k , 使得

$$f(x^{(k)} + \lambda_k d_k) = \min_{\lambda > 0} f(x^{(k)} + \lambda d^{(k)})$$

(4) 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 置 $k := k + 1$, 转到步骤 (2).



■ 最速下降法

➤ 最速下降法

例题

$$\min f(x_1, x_2, x_3) = (x_1)^2 + x_1(1 - x_2) + (x_2)^2 - x_2x_3 + (x_3)^2 + x_3$$

初始值 $\mathbf{x}^{(1)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

允许误差 $\varepsilon = 0.5$



■ 最速下降法

➤ 最速下降法

解：

$$\nabla f(x) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$$

$$d^{(1)} = -\nabla f(x^{(1)}) = \begin{bmatrix} -1 \\ 0 \\ -1 \end{bmatrix}$$

满足截止条件？

$$\|d^{(1)}\| = \sqrt{(-1)^2 + (0)^2 + (-1)^2} = \sqrt{2} > \varepsilon$$

$k = 1$ ，进行第一次迭代

$$x^{(2)} = x^{(1)} + \lambda d^{(1)} = \begin{bmatrix} -\lambda \\ 0 \\ -\lambda \end{bmatrix}$$

确定最优 λ_1



■ 最速下降法

➤ 最速下降法

$$f(x^{(1)} + \lambda d^{(1)}) = 2\lambda^2 - 2\lambda$$

$$\frac{df(x^{(1)} + \lambda d^{(1)})}{d\lambda} = 4\lambda - 2 = 0$$

$$\lambda_1 = \frac{1}{2}$$

$$x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} -\frac{1}{2} \\ 0 \\ 1 \\ -\frac{1}{2} \end{bmatrix}$$

$$d^{(2)} = -\nabla f(x^{(2)}) = \begin{bmatrix} 0 \\ -1 \\ 0 \end{bmatrix}$$



■ 最速下降法

➤ 最速下降法

满足截止条件?

$$\|d^{(2)}\| = \sqrt{(0)^2 + (-1)^2 + (0)^2} = 1 > \varepsilon$$

$k = 2$, 进行第2次迭代

$$x^{(3)} = x^{(2)} + \lambda d^{(2)} = \begin{bmatrix} 1 \\ -\frac{1}{2} \\ -\lambda \\ 1 \\ -\frac{1}{2} \end{bmatrix}$$

确定最优 λ_2

$$f(x^{(2)} + \lambda d^{(2)}) = \lambda^2 - \lambda - \frac{1}{2}$$

$$\frac{df(x^{(2)} + \lambda d^{(2)})}{d\lambda} = 2\lambda - 1 = 0$$

$$\lambda_2 = \frac{1}{2} \quad x^{(3)} = x^{(2)} + \lambda_2 d^{(2)} = \begin{bmatrix} 1 \\ -\frac{1}{2} \\ -\frac{1}{2} \\ 1 \\ -\frac{1}{2} \end{bmatrix}^T$$



■ 最速下降法

➤ 最速下降法

$$d^{(3)} = -\nabla f(x^{(3)}) = \begin{bmatrix} -\frac{1}{2} \\ 0 \\ 1 \\ -\frac{1}{2} \end{bmatrix}$$

满足截止条件?

$$\|d^{(3)}\| = \sqrt{\left(-\frac{1}{2}\right)^2 + (0)^2 + \left(-\frac{1}{2}\right)^2} = \frac{\sqrt{2}}{2} > \varepsilon$$

$k = 3$, 进行第3次迭代

$$x^{(4)} = x^{(3)} + \lambda d^{(3)} = \begin{bmatrix} -\frac{1}{2} \\ 1 \\ -\frac{1}{2} \\ \frac{1}{2} \end{bmatrix} + \begin{bmatrix} -\frac{1}{2}\lambda \\ 0 \\ \frac{1}{2}\lambda \\ -\frac{1}{2}\lambda \end{bmatrix} = \begin{bmatrix} -\frac{1}{2}\lambda - \frac{1}{2} \\ 1 \\ -\frac{1}{2}\lambda - \frac{1}{2} \\ \frac{1}{2} \end{bmatrix}$$



■ 最速下降法

➤ 最速下降法

确定最优 λ_3

$$f(x^{(3)} + \lambda d^{(3)}) = \frac{1}{2}(\lambda + 1)^2 - \frac{3}{2}(\lambda + 1) + \frac{1}{4}$$

$$\lambda_3 = \frac{1}{2} \quad \frac{df(x^{(3)} + \lambda d^{(3)})}{d\lambda} = \lambda + 1 - \frac{3}{2} = 0$$

$$x^{(4)} = x^{(3)} + \lambda_3 d^{(3)} = \begin{bmatrix} 3 \\ -\frac{3}{4} \\ 1 \\ -\frac{1}{2} \\ 2 \\ 3 \\ -\frac{3}{4} \end{bmatrix}$$



■ 最速下降法

➤ 最速下降法

$$d^{(4)} = -\nabla f(x^{(4)}) = \begin{bmatrix} 0 \\ 1 \\ -\frac{1}{2} \\ 0 \end{bmatrix}$$

$$\|d^{(4)}\| = \sqrt{(0)^2 + (-\frac{1}{2})^2 + (0)^2} = \frac{1}{2} \leq \varepsilon$$

满足迭代截止条件

$$x^{(4)} = \begin{bmatrix} -\frac{3}{4} \\ -\frac{1}{2} \\ \frac{3}{4} \\ -\frac{1}{4} \end{bmatrix} \text{ 为满足要求的解}$$



■ 最速下降法

➤ 正交特性

最速下降法极小化目标函数时，相邻两个搜索方向是正交的

Why?


一维搜索函数

$$\varphi(\lambda) = f(x^{(k)} + \lambda d^{(k)}), \quad d^{(k)} = -\nabla f(x^{(k)})$$

$$\dot{\varphi}(\lambda_k) = \nabla f(x^{(k)} + \lambda_k d^{(k)})^T d^{(k)} = 0$$

$$d^{(k+1)} = -\nabla f(x^{(k+1)}) = -\nabla f(x^{(k)} + \lambda_k d^{(k)})$$

因此， $d^{(k)}$ 与 $d^{(k+1)}$ 正交








■ 最速下降法

➤ 锯齿现象

当迭代点接近极小点，每次搜索步长很小，出现锯齿现象，影响收敛速度 **Why?**



- **最速下降方向**反映了目标函数的一种**局部性质**，从全局看其**收敛是比较慢的**
- 最速下降法一般适用于计算过程的**前期迭代**。当接近极小值时，再使用其它算法。



目录

- 最速下降法 (考)
- 牛顿法 (考)
- 共轭梯度法 (考)
- 拟牛顿法
- 信赖域法
- 最小二乘法



■ 牛顿法

- 牛顿法面向哪类优化问题
- 牛顿法的基本思想
- 牛顿法的步长
- 牛顿法的步骤



■ 牛顿法

➤ 适用于的优化问题

无约束优化问题：

$$\min f(\mathbf{x}), \quad \mathbf{x} \in \mathbf{R}^n,$$

其中， $f(x)$ 是二次可微实函数

适用的优化问题：

- 无约束
- 目标函数二次可微



■ 牛顿法

➤ 基本思想

获取函数 $f(x)$ 在点 $x^{(k)}$ 处二阶泰勒近似函数 $\varphi(x)$ ， $\varphi(x)$ 的局部极小点就作为点 $x^{(k+1)}$ 函数逼近法中 牛顿法向多维的推广

$$f(x) \approx f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) + \frac{1}{2} (x - x^{(k)})^T \nabla^2 f(x^{(k)}) (x - x^{(k)}) \\ = \varphi(x)$$

$$\nabla \varphi(x) = \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) (x - x^{(k)}) = 0$$

当海塞矩阵 $\nabla^2 f(x^{(k)})$ 正定

$$\text{局部极小点 } x = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

$$\text{牛顿法的迭代公式: } x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$



■ 牛顿法

➤ 牛顿法的步长

牛顿法的迭代公式：

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

牛顿法的方向：

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

牛顿法的迭代公式由目标函数的一阶导和二阶导确定，对应的步长为1



■ 牛顿法

➤ 牛顿法的步骤

(1) 给定初点 $x^{(1)} \in R^n$, 允许误差 $\varepsilon > 0$, 置 $k = 1$;

(2) 计算 $\nabla f(x^{(k)})$ 和 $\nabla^2 f(x^{(k)})^{-1}$;

(3) 若 $\|\nabla f(x^{(k)})\| \leq \varepsilon$, 停止计算; 否则,
$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

(4) 令 $x^{(k+1)} = x^{(k)} + d^{(k)}$, 置 $k := k + 1$, 转到步骤(2).



■ 牛顿法

➤ 牛顿法

例题

$$\min f(\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3) = (\mathbf{x}_1)^2 + \mathbf{x}_1(1 - \mathbf{x}_2) + (\mathbf{x}_2)^2 - \mathbf{x}_2\mathbf{x}_3 + (\mathbf{x}_3)^2 + \mathbf{x}_3$$

$$\text{初始值 } \mathbf{x}^{(1)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

允许误差 $\varepsilon = 0.5$



■ 牛顿法

➤ 牛顿法

解：

梯度 $\nabla f(x) = \begin{bmatrix} 2x_1 + (1 - x_2) \\ -x_1 + 2x_2 - x_3 \\ -x_2 + 2x_3 + 1 \end{bmatrix}$

海塞矩阵

$$\nabla^2 f(x) = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} \text{ 正定}$$

海塞矩阵的逆

$$\nabla^2 f(x)^{-1} = \begin{bmatrix} 3/4 & 1/2 & 1/4 \\ 1/2 & 1 & 1/2 \\ 1/4 & 1/2 & 3/4 \end{bmatrix}$$



■ 牛顿法

➤ 牛顿法

$$\nabla f(x^{(1)}) = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

满足截止条件?

$$\|\nabla f(x^{(1)})\| = \sqrt{(1)^2 + (0)^2 + (1)^2} = \sqrt{2} > \varepsilon$$

$k = 1$, 进行第一次迭代

$$d^{(1)} = -\nabla^2 f(x^{(1)})^{-1} \nabla f(x^{(1)})$$

$$= - \begin{bmatrix} 3/4 & 1/2 & 1/4 \\ 1/2 & 1 & 1/2 \\ 1/4 & 1/2 & 3/4 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} = - \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

$$x^{(2)} = x^{(1)} + d^{(1)} = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$



■ 牛顿法

➤ 牛顿法

$$\nabla f(x^{(2)}) = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\|\nabla f(x^{(2)})\| = \sqrt{(0)^2 + (0)^2 + (0)^2} = 0 < \varepsilon$$

满足迭代截止条件

$$x^* = x^{(2)} = \begin{bmatrix} -1 \\ -1 \\ -1 \end{bmatrix}$$



■ 牛顿法

➤ 二次型函数

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \nabla^2 f(\mathbf{x}^{(k)})^{-1} \nabla f(\mathbf{x}^{(k)})$$

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + \mathbf{c}$$

$$\text{令 } \nabla f(\mathbf{x}) = \mathbf{A} \mathbf{x} + \mathbf{b} = 0 \rightarrow \bar{\mathbf{x}} = -\mathbf{A}^{-1} \mathbf{b} \text{ 最优}$$

牛顿法如何求解？

$$\begin{aligned} \mathbf{x}^{(1)} &= \mathbf{x}^{(0)} - \mathbf{A}^{-1} \nabla f(\mathbf{x}^{(0)}) \\ &= \mathbf{x}^{(0)} - \mathbf{A}^{-1} (\mathbf{A} \mathbf{x}^{(0)} + \mathbf{b}) \\ &= -\mathbf{A}^{-1} \mathbf{b} \end{aligned}$$

对于二次凸函数，牛顿法经过1次迭代达到最优值。


一些算法，把它们用于二次凸函数时，经有限次迭代必达到极小点。这种性质称为二次终止性



■ 牛顿法

➤ 牛顿法的特点

- 牛顿法利用目标函数的一阶和二阶导数
- 减小迭代次数，**但是**提高每次迭代计算量





■ 牛顿法

➤ 牛顿法的特点

- 当初始点远离极小点时，牛顿法可能不收敛 **Why?**

原因之一：牛顿方向不一定是下降方向

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

$$\nabla f(x^{(k)})^T d^{(k)} = -\nabla f(x^{(k)})^T \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

原因之二：即使目标函数值下降，得到的值也未必是沿牛顿方向的极小点。步长为1

- 改进：阻尼牛顿法——沿牛顿方向一维搜索



■ 牛顿法

➤ 阻尼牛顿法

■ 沿牛顿方向一维搜索

迭代公式:

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

搜索方向: 牛顿方向

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

搜索步长:

$$f(x^{(k)} + \lambda_k d_k) = \min_{\lambda > 0} f(x^{(k)} + \lambda d^{(k)}) \quad \text{一维搜索}$$

每次迭代目标函数值有所下降 (绝不会上升)

阻尼: 就是阻碍目标函数值上升



■ 牛顿法

➤ 阻尼牛顿法

■ 计算步骤

(1) 给定初点 $x^{(1)} \in R^n$, 允许误差 $\varepsilon > 0$, 置 $k = 1$;

(2) 计算 $\nabla f(x^{(k)})$ 和 $\nabla^2 f(x^{(k)})^{-1}$;

(3) 若 $\|\nabla f(x^{(k)})\| \leq \varepsilon$, 停止计算; 否则,
$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

(4) 从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 进行一维搜索, 确定最优 λ_k ,
使得 $f(x^{(k)} + \lambda_k d_k) = \min_{\lambda > 0} f(x^{(k)} + \lambda d^{(k)})$

(5) 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 置 $k := k + 1$, 转到步骤(2).



目录

- 最速下降法 (考)
- 牛顿法 (考)
- 共轭梯度法 (考)
- 拟牛顿法
- 信赖域法
- 最小二乘法



■ 共轭梯度法

- 适用的优化问题
- 共轭梯度法的基本思想
- 什么是共轭方向
- 共轭梯度法的性质
- 典型共轭梯度法



■ 共轭梯度法

➤ 适用于的优化问题

无约束优化问题：

$$\min f(\mathbf{x}), \quad \mathbf{x} \in \mathbf{R}^n,$$

其中， $f(x)$ 具有一阶连续偏导数

适用的优化问题：


- 无约束
- 目标函数一阶连续偏导



■ 共轭梯度法

➤ 基本思想

最速下降法极小化目标函数时，**相邻两个搜索方向是正交的**



把**共轭性**和**最速下降法**相结合，利用已知点 $x^{(k)}$ 处的梯度构造一组**共轭方向**，并沿着这组方向进行搜索，求出目标函数的极小点。

需要了解：**共轭方向**

需要掌握：**共轭方向的构造方法**



■ 共轭梯度法

➤ 共轭方向


◆ 定义10. 3. 1 设 A 是 $n \times n$ 对称正定矩阵，若 E^n 中的两个方向 $d^{(1)}$ 和 $d^{(2)}$ 满足

$$d^{(1)T} A d^{(2)} = 0 \quad (10. 3. 1)$$

则称这两个方向关于 A 共轭，或称它们关于 A 正交。

◆ 共轭是正交概念的推广

如 A 为单位矩阵，则两个方向关于 A 共轭等价于两个方向正交

$$d^{(i)T} A d^{(j)} = 0$$


正交



■ 共轭梯度法

➤ 共轭方向的几何意义

设有二次函数

$$f(\mathbf{x}) = \frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}})^T \mathbf{A} (\mathbf{x} - \bar{\mathbf{x}})$$

\mathbf{A} 是 $f(x)$ **对称的正定矩阵**, $\bar{\mathbf{x}}$ 为定点。

函数 $f(\mathbf{x})$ **等值面**为


$$\frac{1}{2} (\mathbf{x} - \bar{\mathbf{x}})^T \mathbf{A} (\mathbf{x} - \bar{\mathbf{x}}) = c \quad \Rightarrow \quad \text{以 } \bar{\mathbf{x}} \text{ 为中心的椭球面}$$

若 $\left. \begin{array}{l} \nabla f(\mathbf{x}) = \mathbf{A}(\mathbf{x} - \bar{\mathbf{x}}) = 0 \\ \mathbf{A} \text{ 正定} \end{array} \right\} \Rightarrow \bar{\mathbf{x}} \text{ 为 } f(\mathbf{x}) \text{ 的局部极小值}$



■ 共轭梯度法

➤ 共轭方向的几何意义



■ 共轭梯度法

➤ 共轭方向的几何意义

设 $\mathbf{x}^{(1)}$ 是在某个等值面上的一点
该等值面在点 $\mathbf{x}^{(1)}$ 处的法向量

$$\nabla f(\mathbf{x}^{(1)}) = A(\mathbf{x}^{(1)} - \bar{\mathbf{x}})$$


$$\mathbf{d}^{(2)} = \bar{\mathbf{x}} - \mathbf{x}^{(1)}$$

$$\nabla f(\mathbf{x}^{(1)}) = -A\mathbf{d}^{(2)}$$

又设 $\mathbf{d}^{(1)}$ 是这个等值面在 $\mathbf{x}^{(1)}$ 处的一个切向

自 $\mathbf{d}^{(1)}$ 与 $\nabla f(\mathbf{x}^{(1)})$ 正交

因此有: $\mathbf{d}^{(1)T} A \mathbf{d}^{(2)} = 0$



等值面上一点处的切向量与由这一点指向极小点的向量
关于A共轭



■ 共轭梯度法

➤ 共轭梯度的性质

- 提高最速下降法的收敛速度，无需牛顿法计算海塞矩阵
- 目标函数为二次型，有限次迭代收敛至最优值
- 影响迭代搜索效率关键是搜索方向，对于二次型目标函数最好的搜索方向为共轭方向
- 也可求解非二次型目标函数



■ 共轭梯度法

➤ 典型共轭梯度法

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + \mathbf{c}$$

➤ **迭代公式** $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$

➤ **搜索方向** $d^{(1)}, \dots, d^{(k)}$ **关于A共轭**
 $d^{(i)} \mathbf{A} d^{(j)} = 0 \quad i \neq j$

➤ **搜索步长:** $\lambda_k = \arg \min_{\lambda > 0} f(x^{(k)} + \lambda d^{(k)})$ **一维搜索**

需讨论如何构造共轭方向，确定最优步长



■ 共轭梯度法

➤ 典型共轭梯度法

- 第 k 次迭代结束后，利用 $d^{(k)}$ 和负梯度 $-\nabla f(x^{(k+1)})$ 构造下一个搜索方向 $d^{(k+1)}$

$$d^{(k+1)} = -\nabla f(x^{(k+1)}) + \beta_k d^{(k)} \quad \text{如何确定}\beta_k?$$

正交 $(d^{(k)})^T A d^{(k+1)} = 0$

$$(d^{(k)})^T A (-\nabla f(x^{(k+1)}) + \beta_k d^{(k)}) = 0$$

$$-(d^{(k)})^T A \nabla f(x^{(k+1)}) + \beta_k (d^{(k)})^T A d^{(k)} = 0$$

$$\beta_k = \frac{(d^{(k)})^T A \nabla f(x^{(k+1)})}{(d^{(k)})^T A d^{(k)}} = \frac{(d^{(k)})^T A g_{k+1}}{(d^{(k)})^T A d^{(k)}} \quad g_{k+1} = \nabla f(x^{(k+1)})$$



■ 共轭梯度法

➤ 典型共轭梯度法

➤ 确定最优步长 λ_k

$$f(x^{(k)} + \lambda_k d_k) = \min_{\lambda > 0} f(x^{(k)} + \lambda d^{(k)})$$

$$\varphi(\lambda) = f(x^{(k)} + \lambda d^{(k)})$$

$$\dot{\varphi}(\lambda) = \frac{df(x^{(k)} + \lambda d^{(k)})}{d\lambda} = \nabla f(x^{(k)} + \lambda d^{(k)})^T d^{(k)}$$

$$= (Ax^{(k)} + \lambda Ad^{(k)} + b)^T d^{(k)}$$

$$= (g_k + \lambda Ad^{(k)})^T d^{(k)}$$

$$= g_k^T d^{(k)} + \lambda d^{(k)T} Ad^{(k)} = 0$$

$$\lambda_k = -\frac{g_k^T d^{(k)}}{d^{(k)T} Ad^{(k)}} \quad 46$$



■ 共轭梯度法

➤ 典型共轭梯度法的步骤

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + \mathbf{c}$$

(1) 给定初点 $\mathbf{x}^{(1)} \in R^n$, 允许误差 $\varepsilon > 0$, 置 $k = 1$;

(2) 计算 $\mathbf{g}_k = \nabla f(\mathbf{x}^{(k)})$, 若 $\|\mathbf{g}_k\| = 0$, 停止计算; 否则进行步骤(3);

(3) 构造搜索方向

$$\mathbf{d}^{(k)} = \begin{cases} -\mathbf{g}_k, & k = 1 \\ -\mathbf{g}_k + \beta_{k-1} \mathbf{d}^{(k-1)}, & k > 1 \end{cases}$$

(4) 从 $\mathbf{x}^{(k)}$ 出发, 沿 $\mathbf{d}^{(k)}$ 进行一维搜索, 确定最优 λ_k

$$\lambda_k = \arg \min_{\lambda} f(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)}) = -\frac{\mathbf{g}_k^T \mathbf{d}^{(k)}}{\mathbf{d}^{(k)T} \mathbf{A} \mathbf{d}^{(k)}}$$

(5) 若 $k = n$, 则停止计算; 否则, $k := k + 1$, 返回步骤(3)



■ 共轭梯度法

➤ 典型共轭梯度法

求解二次型目标函数

$$\min_x x_1^2 + 2x_2^2$$

初始值 $x^{(1)} = (5, 5)^T$

允许误差 $\varepsilon = 0.5$



■ 共轭梯度法

➤ 典型共轭法

解：梯度

$$\nabla f(\mathbf{x}) = \begin{bmatrix} 2x_1 \\ 4x_2 \end{bmatrix} \quad \mathbf{g}_1 = \nabla f(\mathbf{x}^{(1)}) = \begin{bmatrix} 10 \\ 20 \end{bmatrix}$$

$$\|\mathbf{g}_1\| = \sqrt{(10)^2 + (20)^2} > 0$$

$$\text{第1次迭代: } \mathbf{d}^{(1)} = -\mathbf{g}_1 = \begin{bmatrix} -10 \\ -20 \end{bmatrix}$$

从 $\mathbf{x}^{(1)}$ 出发，沿方向 $\mathbf{d}^{(1)}$ 做一维搜索，求 λ_1

$$\lambda_1 = -\frac{\mathbf{g}_1^T \mathbf{d}^{(1)}}{\mathbf{d}^{(1)T} \mathbf{A} \mathbf{d}^{(1)}} = \frac{[-10 \ -20] \begin{bmatrix} -10 \\ -20 \end{bmatrix}}{[-10 \ -20] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} -10 \\ -20 \end{bmatrix}} = \frac{5}{18}$$

$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} 5 \\ 5 \end{bmatrix} + \frac{5}{18} \begin{bmatrix} -10 \\ -20 \end{bmatrix} = \begin{bmatrix} \frac{20}{9} \\ -\frac{5}{9} \end{bmatrix}$$



■ 共轭梯度法

➤ 典型梯度法

$$\mathbf{g}_2 = \nabla f(\mathbf{x}^{(2)}) = \begin{bmatrix} 40 \\ 9 \end{bmatrix} - \frac{20}{9} \begin{bmatrix} 2 \\ 0 \end{bmatrix} \quad \|\mathbf{g}_2\| > 0$$

第2次迭代:

构造搜索方向: $\mathbf{d}^{(2)} = -\mathbf{g}_2 + \beta_1 \mathbf{d}^{(1)}$, 需求 β_1

$$\beta_1 = \frac{(\mathbf{d}^{(1)})^T \mathbf{A} \nabla f(\mathbf{x}^{(2)})}{(\mathbf{d}^{(1)})^T \mathbf{A} (\mathbf{d}^{(1)})} = \frac{[-10 \ -20] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} \frac{40}{9} \\ -\frac{20}{9} \end{bmatrix}}{[-10 \ -20] \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} -10 \\ -20 \end{bmatrix}} = \frac{4}{81}$$

从 $\mathbf{x}^{(2)}$ 出发, 沿方向 $\mathbf{d}^{(2)}$ 做一维搜索, 求 λ_2

$$\lambda_2 = -\frac{\mathbf{g}_2^T \mathbf{d}^{(2)}}{\mathbf{d}^{(2)T} \mathbf{A} \mathbf{d}^{(2)}} = \frac{9}{20} \quad \mathbf{x}^{(3)} = \mathbf{x}^{(2)} + \lambda_2 \mathbf{d}^{(2)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\mathbf{g}_3 = \nabla f(\mathbf{x}^{(3)}) = [0 \ 0]^T \quad \|\mathbf{g}_3\| = 0 \quad \mathbf{x}^* = \mathbf{x}^{(3)}$$



■ 共轭梯度法

➤ 典型梯度法

■ 求解一般函数

- 步长无法采用公式，只能用一维搜索确定

$$\lambda_{k+1} = \arg \min_{\lambda > 0} f(x^{(k+1)} + \lambda d^{(k+1)})$$

- 当前点的海塞矩阵替代A

$$\beta_k = \frac{(d^{(k)})^T \mathbf{A} \nabla f(\mathbf{x}^{k+1})}{(d^{(k)})^T \mathbf{A} d^{(k)}} \quad \nabla^2 f(\mathbf{x}^{k+1}) \rightarrow \mathbf{A}$$

- 求解一般函数问题，有限步迭代达不到最优



■ 作业

P330:

2、14(偶数)

P331:

19（本章完结再做）