

Optimal Theory and Method

最优化理论与方法

翟春杰

杭州电子科技大学 自动化学院
科技馆512

Email: cjzhai@hdu.edu.cn



目录

- 最速下降法
- 牛顿法
- 共轭梯度法
- 拟牛顿法
- 最小二乘法
- 信赖域法



目录

- 最速下降法
- 牛顿法
- 共轭梯度法
- 拟牛顿法
- 最小二乘法
- 信赖域法



■ 牛顿法

➤ 牛顿法的特点

- 当初始点远离极小点时，牛顿法可能不收敛 **Why?**

原因之一：牛顿方向不一定是下降方向

$$d^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

$$\nabla f(x^{(k)})^T d^{(k)} = -\nabla f(x^{(k)})^T \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

原因之二：即使目标函数值下降，得到的值也未必是沿牛顿方向的极小点。步长为1

- **改进：阻尼牛顿法——沿牛顿方向一维搜索**



拟牛顿法

■ 算法产生

◆ 牛顿法

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \left(\nabla^2 f(\mathbf{x}^{(k)}) \right)^{-1} \nabla f(\mathbf{x}^{(k)})$$

◆ 思路：用不包含二阶导数的矩阵近似海塞矩阵

◆ 关键：近似矩阵的构造

◆ 构造近似矩阵的方法不同，产生不同的拟牛顿法

◆ 拟牛顿法是一类算法，而不是一个算法：秩1校正法、DFP算法、BFGS法



拟牛顿法

■ 拟牛顿条件

目标函数在点 $\mathbf{x}^{(k+1)}$ 展成泰勒级数，并取二阶近似

$$f(\mathbf{x}) \approx f(\mathbf{x}^{(k+1)}) + \nabla f(\mathbf{x}^{(k+1)})^T (\mathbf{x} - \mathbf{x}^{(k+1)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k+1)})^T \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

对上式 \approx 两边同时求关于 \mathbf{x} 的梯度，得

$$\nabla f(\mathbf{x}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)})$$

令 $\mathbf{x} = \mathbf{x}^{(k)}$ ，则 $\nabla f(\mathbf{x}^{(k)}) \approx \nabla f(\mathbf{x}^{(k+1)}) + \nabla^2 f(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)})$

记 $p^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ $q^{(k)} = \nabla f(\mathbf{x}^{(k+1)}) - \nabla f(\mathbf{x}^{(k)})$

则有 $q^{(k)} \approx \nabla^2 f(\mathbf{x}^{(k+1)}) p^{(k)}$

设海塞矩阵可逆 $p^{(k)} \approx \nabla^2 f(\mathbf{x}^{(k+1)})^{-1} q^{(k)}$

令 H_{k+1} 满足

$$p^{(k)} = H_{k+1} q^{(k)}$$

拟牛顿条件：pH值+1



拟牛顿法

■ 近似矩阵的构造

➤ 当 $\nabla^2 f(\mathbf{x}^{(k+1)})^{-1}$ 是 n 阶对称正定矩阵时，满足拟牛顿条件的矩阵 H_{k+1} 也是 n 阶对称正定矩阵

➤ 构造矩阵 H_k 的策略

- 初始选择任一 n 阶对称正定矩阵，一般 $H_1 = I$

- 对近似矩阵迭代计算

$$H_{k+1} = H_k + \Delta H_k$$

校正矩阵 ΔH_k



拟牛顿法

■ DFP (变尺度法)

- DFP (变尺度法) 计算校正矩阵

$$\nabla H_k = \frac{\mathbf{p}^{(k)}(\mathbf{p}^{(k)})^T}{(\mathbf{p}^{(k)})^T \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)T} \mathbf{H}_k}{(\mathbf{q}^{(k)})^T \mathbf{H}_k \mathbf{q}^{(k)}}$$

- DFP公式

$$\mathbf{H}_{k+1} = \mathbf{H}_k + \frac{\mathbf{p}^{(k)}(\mathbf{p}^{(k)})^T}{(\mathbf{p}^{(k)})^T \mathbf{q}^{(k)}} - \frac{\mathbf{H}_k \mathbf{q}^{(k)} \mathbf{q}^{(k)T} \mathbf{H}_k}{(\mathbf{q}^{(k)})^T \mathbf{H}_k \mathbf{q}^{(k)}}$$

$$\mathbf{p}^{(k)} = \mathbf{H}_{k+1} \mathbf{q}^{(k)}$$

拟牛顿条件成立吗?



拟牛顿法

■ DFP (变尺度法) 拟牛顿条件验证

- DFP公式

$$H_{k+1} = H_k + \frac{p^{(k)}(p^{(k)})^T}{(p^{(k)})^T q^{(k)}} - \frac{H_k q^{(k)} q^{(k)T} H_k}{(q^{(k)})^T H_k q^{(k)}}$$

$$H_{k+1} q^{(k)} = \left[H_k + \frac{p^{(k)}(p^{(k)})^T}{(p^{(k)})^T q^{(k)}} - \frac{H_k q^{(k)} q^{(k)T} H_k}{(q^{(k)})^T H_k q^{(k)}} \right] q^{(k)}$$

$$= H_k q^{(k)} + \frac{p^{(k)}(p^{(k)})^T q^{(k)}}{(p^{(k)})^T q^{(k)}} - \frac{H_k q^{(k)} q^{(k)T} H_k q^{(k)}}{(q^{(k)})^T H_k q^{(k)}}$$

$$= H_k q^{(k)} + p^{(k)} - H_k q^{(k)} = p^{(k)}$$



拟牛顿法

■ DFP算法步骤

步骤1：给定初始点 $x^{(1)} \in \mathbf{E}^n$,允许误差 $\varepsilon < 0$

步骤2：置 $H_1 = I_n$ (单位矩阵) , 计算 $x^{(1)}$ 处的梯度 $g_1 = \nabla f(x^{(1)})$,置 $k=1$

步骤3：令 $d^{(k)} = -H_k g_k$

步骤4：从 $x^{(k)}$ 出发, 沿方向 $d^{(k)}$ 搜索, 求步长 λ_k 使其满足 $f(x^{(k)} + \lambda_k d^{(k)}) = \min f(x^{(k)} + \lambda d^{(k)})$

$$\text{令 } x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$



拟牛顿法

■ DFP算法步骤

步骤5：检验是否满足收敛准则，若 $\|\nabla f(x^{(1)})\| \leq \varepsilon$ ，则停止迭代，得到点 $x^* = x^{(k+1)}$ ；否则，转到步骤6

步骤6：若 $k=n$ ，则令 $x^1 = x^{(k+1)}$ ，返回步骤2；否则，进行步骤7

步骤7：令 $g_{k+1} = \nabla f(x^{(k+1)})$, $p^{(k)} = x^{(k+1)} - x^{(k)}$,
 $q^{(k)} = g_{k+1} - g_k$ 。利用公式 (10.4.17) 计算 H_{k+1} , 置
 $k:=k+1$, 转到步骤3



拟牛顿法

■ 例子——用DFP求解以下问题

$$\min 2x_1^2 + x_2^2 - 4x_1 + 2$$

初始点及初始矩阵分别取

梯度

$$\mathbf{x}^{(1)} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad \mathbf{H}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad \mathbf{g} = \begin{bmatrix} 4(x_1 - 1) \\ 2x_2 \end{bmatrix}$$

第**1**次迭代:

$$\text{在 } \mathbf{x}^{(1)} \text{ 处的梯度: } \mathbf{g}_1 = \begin{bmatrix} 4 \\ 2 \end{bmatrix} \quad \|\mathbf{g}_1\| > 0$$

$$\text{在 } \mathbf{x}^{(1)} \text{ 处的搜索方向: } \mathbf{d}^{(1)} = -\mathbf{H}_1 \mathbf{g}_1 = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$$

$$\mathbf{d}^{(1)} = -\mathbf{g}_1 = \begin{bmatrix} -4 \\ -2 \end{bmatrix}$$



拟牛顿法

■ 例子——用DFP求解以下问题

从 $\mathbf{x}^{(1)}$ 出发沿 $\mathbf{d}^{(1)}$ 作一维搜索，求步长 λ_1 ：

$$\min_{\lambda \geq 0} f(\mathbf{x}^{(1)} + \lambda \mathbf{d}^{(1)}), \text{ 得 } \lambda_1 = 5/18$$

$$\longrightarrow \mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \frac{5}{18} \begin{bmatrix} -4 \\ -2 \end{bmatrix} = \begin{bmatrix} \frac{8}{9} \\ \frac{4}{9} \end{bmatrix}$$

在 $\mathbf{x}^{(2)}$ 处的梯度：

$$\mathbf{g}_2 = \begin{bmatrix} 4(\frac{8}{9} - 1) \\ 2 \cdot \frac{4}{9} \end{bmatrix} = \begin{bmatrix} -\frac{4}{9} \\ \frac{8}{9} \end{bmatrix} \quad \|\mathbf{g}_2\| > 0 \longrightarrow \text{进行第2次迭代}$$



拟牛顿法

■ 例子——用DFP求解以下问题

第2次迭代:

$$\mathbf{p}^{(1)} = \mathbf{x}^{(2)} - \mathbf{x}^{(1)} = \lambda_1 \mathbf{d}^{(1)} = \begin{bmatrix} -\frac{10}{9} \\ 5 \\ -\frac{9}{9} \end{bmatrix}$$

$$\mathbf{q}^{(1)} = \mathbf{g}_2 - \mathbf{g}_1 = \begin{bmatrix} -\frac{4}{9} \\ 8 \\ \frac{9}{9} \end{bmatrix} - \begin{bmatrix} 4 \\ 2 \end{bmatrix} = \begin{bmatrix} -\frac{40}{9} \\ 10 \\ -\frac{9}{9} \end{bmatrix}$$



拟牛顿法

■ 例子——用DFP求解以下问题

计算 H_2 :

$$H_2 = H_1 + \frac{p^{(1)}p^{(1)T}}{p^{(1)T}q^{(1)}} - \frac{H_1 q^{(1)} q^{(1)T} H_1}{q^{(1)T} H_1 q^{(1)}} = \frac{1}{306} \begin{bmatrix} 86 & -38 \\ -38 & 305 \end{bmatrix}$$

在 $x^{(2)}$ 处的搜索方向: $d^{(2)} = -H_2 g_2 = \frac{12}{51} \begin{bmatrix} 1 \\ -4 \end{bmatrix}$

从 $x^{(2)}$ 出发沿 $d^{(2)}$ 作一维搜索, 求步长 λ_2 :

$$\min_{\lambda \geq 0} f(x^{(2)} + \lambda d^{(2)}), \text{ 得 } \lambda_2 = 17/36$$

$$\longrightarrow x^{(3)} = x^{(2)} + \lambda_2 d^{(2)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad g_3 = \begin{bmatrix} 4(1-1) \\ 2 \cdot 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$\|g_3\|=0$ 迭代终止 最优点 $x^* = x^{(3)}$



拟牛顿法

由**Broyden**, **Fletcher**, **Goldfarb**和
Shanno于1970年提出

■ BFGS

- 另一种形式拟牛顿条件

$$q^{(k)} = B_{k+1} p^{(k)}$$

- 递推公式

$$B_{k+1} = B_k + \frac{(q^{(k)})^T q^{(k)}}{(q^{(k)})^T p^{(k)}} - \frac{(B_k p^{(k)})^T p^{(k)} B_k}{(p^{(k)})^T B_k p^{(k)}}$$

- 令 $H_{k+1} = B_{k+1}^{-1}$

$$H_{k+1} = H_k + \left(1 + \frac{(q^{(k)})^T H_k q^{(k)}}{(p^{(k)})^T q^{(k)}}\right) \frac{p^{(k)} (p^{(k)})^T}{(p^{(k)})^T q^{(k)}}$$

- 数值计算经验表明

比DFP公式还好，因此得到广泛应用



拟牛顿法

■ 讨论

• 优点

- 无约束最优化方法中最有效的一类算法
- 迭代仅需一阶导数，不必计算海塞矩阵

$$g_{k+1} = \nabla f(x^{(k+1)})$$

- 当矩阵 H_k 正定，算法产生的方向为下降方向，具有二次终止性

• 缺点

- 存储量大，不宜适用于大型优化问题。



目录

- 最速下降法
- 牛顿法
- 共轭梯度法
- 拟牛顿法
- 最小二乘法
- 信赖域法



最小二乘法

■ 最小二乘问题

设目标函数由若干个函数的平方和构成，一般写成

$$F(\mathbf{x}) = \sum_{i=1}^m f_i^2(\mathbf{x}), \quad \mathbf{x} = (x_1, x_2, \dots, x_n)^T$$

则极小化 $F(\mathbf{x})$ 这类函数的问题

$$\min_{\mathbf{x}} F(\mathbf{x}) = \sum_{i=1}^m f_i^2(\mathbf{x})$$

称为最小二乘问题

- ◆ $f_i(\mathbf{x})$ 为 \mathbf{x} 的线性函数时，则为线性最小二乘问题
- ◆ $f_i(\mathbf{x})$ 为 \mathbf{x} 的非线性函数时，则为非线性最小二乘问题



最小二乘法

■ 线性最小二乘问题

假设 $f_i(x) = \mathbf{p}_i^T \mathbf{x} - b_i$, \mathbf{p}_i 为 n 维列向量, b_i 为实数

令
$$\mathbf{A} = \begin{bmatrix} \mathbf{p}_1^T \\ \vdots \\ \mathbf{p}_m^T \end{bmatrix}, \mathbf{b} = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix},$$

则有
$$F(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})) \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix}$$

$$\begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ \vdots \\ f_m(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \mathbf{p}_1^T \mathbf{x} - b_1 \\ \mathbf{p}_2^T \mathbf{x} - b_2 \\ \vdots \\ \mathbf{p}_m^T \mathbf{x} - b_m \end{bmatrix} = \begin{bmatrix} \mathbf{p}_1^T \mathbf{x} \\ \mathbf{p}_2^T \mathbf{x} \\ \vdots \\ \mathbf{p}_m^T \mathbf{x} \end{bmatrix} - \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} = \mathbf{A}\mathbf{x} - \mathbf{b}$$



最小二乘法

■ 线性最小二乘问题

所以 $F(\mathbf{x}) = (\mathbf{Ax} - \mathbf{b})^T (\mathbf{Ax} - \mathbf{b})$

$$= (\mathbf{x}^T \mathbf{A}^T - \mathbf{b}^T)(\mathbf{Ax} - \mathbf{b})$$

$$\begin{aligned} \mathbf{b}^T \mathbf{Ax} &= (\mathbf{x}^T \mathbf{A}^T \mathbf{b})^T \\ &\text{一个实数} \\ &= \mathbf{x}^T \mathbf{A}^T \mathbf{Ax} - \mathbf{x}^T \mathbf{A}^T \mathbf{b} - \mathbf{b}^T \mathbf{Ax} + \mathbf{b}^T \mathbf{b} \\ &= \mathbf{x}^T \mathbf{A}^T \mathbf{Ax} - 2\mathbf{b}^T \mathbf{Ax} + \mathbf{b}^T \mathbf{b} \end{aligned}$$

$$\text{令 } \nabla F(\mathbf{x}) = 2\mathbf{A}^T \mathbf{Ax} - 2\mathbf{A}^T \mathbf{b} = 0$$

$$F(\mathbf{x}) \text{ 的极小点满足 } \mathbf{A}^T \mathbf{Ax} = \mathbf{A}^T \mathbf{b}$$

设 \mathbf{A} 列满秩, $\mathbf{A}^T \mathbf{A}$ 为 n 阶 **对称正定矩阵**

凸函数 $F(\mathbf{x})$ 的全局极小点 $\bar{\mathbf{x}} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$



最小二乘法

■ 线性最小二乘问题求解

给定方程组
$$\begin{cases} x_1 + x_2 = 3 \\ 2x_1 - 3x_2 = 2 \\ -x_1 + 4x_2 = 4 \end{cases}$$

记系数矩阵为 A ，右端向量为 b ，求函数
 $f(x) = (Ax - b)^T(Ax - b)$ 的极小点。

$$A = \begin{bmatrix} 1 & 1 \\ 2 & -3 \\ -1 & 4 \end{bmatrix}, b = \begin{bmatrix} 3 \\ 2 \\ 4 \end{bmatrix}$$

进一步得到

$$A^T A = \begin{bmatrix} 6 & -9 \\ -9 & 26 \end{bmatrix}, A^T A \text{非奇异}, (A^T A)^{-1} = \frac{1}{75} \begin{bmatrix} 26 & 9 \\ 9 & 6 \end{bmatrix}$$



最小二乘法

■ 线性最小二乘问题求解

根据公式 $\bar{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b}$

$$\bar{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b} = \frac{1}{75} \begin{bmatrix} 26 & 9 \\ 9 & 6 \end{bmatrix} \begin{bmatrix} 1 & 2 & -1 \\ 1 & -3 & 4 \end{bmatrix} \begin{bmatrix} 3 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} \frac{13}{5} \\ \frac{7}{5} \end{bmatrix}$$

极小点 $\bar{\mathbf{x}}$ 也称为最小二乘解。

$$f_{min} = f(\bar{\mathbf{x}}) = (\mathbf{A}\bar{\mathbf{x}} - \mathbf{b})^T (\mathbf{A}\bar{\mathbf{x}} - \mathbf{b}) = 3 \neq 0$$

$$\text{方程组} \begin{cases} x_1 + x_2 = 3 \\ 2x_1 - 3x_2 = 2 \\ -x_1 + 4x_2 = 4 \end{cases} \text{无解}$$

若方程组有解，最小二乘解，也是 $\mathbf{f}(\mathbf{x})$ 的解



最小二乘法

■ 非线性最小二乘问题

$$\min_x F(\mathbf{x}) = \sum_{i=1}^m f_i^2(\mathbf{x})$$

$f_i(\mathbf{x})$ 是非线性函数, $F(\mathbf{x})$ 存在连续偏导数

求解思路:

- 通过解一系列线性最小二乘问题不断逼近非线性最小二乘问题的解
- 具体要用线性函数近似非线性函数



最小二乘法

■ 非线性最小二乘问题

设 $\mathbf{x}^{(k)}$ 是解的第 k 次近似

$f_i(\mathbf{x})$ 在 $\mathbf{x}^{(k)}$ 处展开一阶**Taylor**多项式，得线性近似函数

$$\varphi_i(\mathbf{x}) = f_i(\mathbf{x}^{(k)}) + \nabla f_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \approx f_i(\mathbf{x})$$

$$\text{令 } \phi(\mathbf{x}) = \sum_{i=1}^m \varphi_i^2(\mathbf{x}), \quad \text{用 } \phi(\mathbf{x}) \text{ 近似 } F(\mathbf{x})$$

于是用 $\phi(\mathbf{x})$ 的极小点作为目标函数 $F(\mathbf{x})$ 的估计



最小二乘法

■ 非线性最小二乘问题

$$\begin{aligned}\varphi_i(\mathbf{x}) &= f_i(\mathbf{x}^{(k)}) + \nabla f_i(\mathbf{x}^{(k)})^T (\mathbf{x} - \mathbf{x}^{(k)}) \\ &= \nabla f_i(\mathbf{x}^{(k)})^T \mathbf{x} - \left(\nabla f_i(\mathbf{x}^{(k)})^T \mathbf{x}^{(k)} - f_i(\mathbf{x}^{(k)}) \right)\end{aligned}$$

令

$$\mathbf{A}_k = \begin{bmatrix} \nabla f_1(\mathbf{x}^{(k)})^T \\ \vdots \\ \nabla f_m(\mathbf{x}^{(k)})^T \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1(\mathbf{x}^{(k)})}{\partial x_1} & \cdots & \frac{\partial f_1(\mathbf{x}^{(k)})}{\partial x_n} \\ \vdots & \vdots & \vdots \\ \frac{\partial f_m(\mathbf{x}^{(k)})}{\partial x_1} & \cdots & \frac{\partial f_m(\mathbf{x}^{(k)})}{\partial x_n} \end{bmatrix} \quad \mathbf{f}^{(k)} = \begin{bmatrix} f_1(\mathbf{x}^{(k)}) \\ \vdots \\ f_m(\mathbf{x}^{(k)}) \end{bmatrix}$$

$$\mathbf{b} = \begin{bmatrix} \nabla f_1(\mathbf{x}^{(k)})^T \mathbf{x}^{(k)} - f_1(\mathbf{x}^{(k)}) \\ \vdots \\ \nabla f_m(\mathbf{x}^{(k)})^T \mathbf{x}^{(k)} - f_m(\mathbf{x}^{(k)}) \end{bmatrix} = \mathbf{A}_k \mathbf{x}^{(k)} - \mathbf{f}^{(k)},$$



最小二乘法

■ 非线性最小二乘问题

$$\begin{aligned}\text{所以 } \phi(\mathbf{x}) &= (\mathbf{A}_k \mathbf{x} - \mathbf{b})^T (\mathbf{A}_k \mathbf{x} - \mathbf{b}), \mathbf{b} = \mathbf{A}_k \mathbf{x}^{(k)} - f^{(k)} \\ &= (\mathbf{A}_k \mathbf{x} - \mathbf{A}_k \mathbf{x}^{(k)} + f^{(k)})^T (\mathbf{A}_k \mathbf{x} - \mathbf{A}_k \mathbf{x}^{(k)} + f^{(k)}) \\ &= (\mathbf{A}_k (\mathbf{x} - \mathbf{x}^{(k)}) + f^{(k)})^T (\mathbf{A}_k (\mathbf{x} - \mathbf{x}^{(k)}) + f^{(k)})\end{aligned}$$

$$\text{令 } \nabla \phi(\mathbf{x}) = 2\mathbf{A}_k^T \mathbf{A}_k (\mathbf{x} - \mathbf{x}^{(k)}) - 2\mathbf{A}_k^T (\mathbf{A}_k \mathbf{x}^{(k)} - f^{(k)}) = 0$$

$$\text{则 } \mathbf{A}_k^T \mathbf{A}_k (\mathbf{x} - \mathbf{x}^{(k)}) = -\mathbf{A}_k^T f^{(k)}$$

设 \mathbf{A}_k 列满秩, $\mathbf{A}_k^T \mathbf{A}_k$ 为 n 阶对称正定矩阵

$$\phi(\mathbf{x}) \text{ 的极小点 } \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - (\mathbf{A}_k^T \mathbf{A}_k)^{-1} \mathbf{A}_k^T f^{(k)}$$

$\mathbf{x}^{(k+1)}$ 为 $F(\mathbf{x})$ 的极小点的第 $k+1$ 次近似。



最小二乘法

■ 非线性最小二乘问题

$$\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} - (A_k^T A_k)^{-1} A_k^T f^{(k)} \quad \text{Causs-Newton公式}$$

$$\boldsymbol{d}^{(k)} = -(A_k^T A_k)^{-1} A_k^T f^{(k)} \quad \text{Causs-Newton方向}$$

在求出 $\boldsymbol{d}^{(k)}$ 后，为保证目标函数下降（至少不上升）
不直接用 $\boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \boldsymbol{d}^{(k)}$ 作为第 $k+1$ 次近似

沿着 $\boldsymbol{d}^{(k)}$ 方向一维搜索获得 λ_k

$$\min_{\lambda} F(\boldsymbol{x}^{(k)} + \lambda \boldsymbol{d}^{(k)})$$
$$\longrightarrow \boldsymbol{x}^{(k+1)} = \boldsymbol{x}^{(k)} + \lambda_k \boldsymbol{d}^{(k)}$$

$\boldsymbol{x}^{(k+1)}$ 为 $F(\boldsymbol{x})$ 的极小点的第 $k+1$ 次近似。



最小二乘法

■ 非线性最小二乘算法步骤

步骤1：给定初始点 $\mathbf{x}^{(1)} \in \mathbf{E}^n$, 允许误差 $\varepsilon > 0$

步骤2：计算函数值 $f_i(\mathbf{x}^{(k)}) (i = 1, 2, \dots, m)$, 求

$$\mathbf{f}^{(k)} = \begin{bmatrix} f_1(\mathbf{x}^{(k)}) \\ f_2(\mathbf{x}^{(k)}) \\ \vdots \\ f_m(\mathbf{x}^{(k)}) \end{bmatrix}, \quad \mathbf{a}_{ij} = \frac{\partial f_i(\mathbf{x}^{(k)})}{\partial x_j}, \quad \mathbf{A}_k = (\mathbf{a}_{ij})_{m \times n}$$

步骤3：求causs-newton方向

$$\mathbf{d}^{(k)} = -(\mathbf{A}_k^T \mathbf{A}_k)^{-1} \mathbf{A}_k^T \mathbf{f}^{(k)}$$



最小二乘法

■ 非线性最小二乘算法步骤

步骤4：从 $\mathbf{x}^{(k)}$ 出发，沿方向 $\mathbf{d}^{(k)}$ 搜索，求步长 λ_k 使其满足

$$F(\mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}) = \min F(\mathbf{x}^{(k)} + \lambda \mathbf{d}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \mathbf{d}^{(k)}$$

步骤5：若 $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \varepsilon$ ，则停止迭代，得到点 $\bar{\mathbf{x}} = \mathbf{x}^{(k+1)}$ ；否则，转到步骤2



最小二乘法

■ 讨论

• 线性最小二乘问题

➤ 直接用下面的公式求最小二乘解

$$\bar{x} = (A^T A)^{-1} A^T b$$

• 非线性最小二乘问题

➤ 需要迭代，使用线性近似函数确定搜索方向

$$d^{(k)} = -\left(A_k^T A_k\right)^{-1} A_k^T f^{(k)}$$

➤ 需要通过多次迭代逐步逼近最小二乘解。

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$



目录

- 最速下降法
- 牛顿法
- 共轭梯度法
- 拟牛顿法
- 最小二乘法
- 信赖域法



信赖域法

- 迭代方法一般策略是，给定点 $x^{(k)}$ 后，确定搜索方向 $d^{(k)}$ ，再从点 $x^{(k)}$ 出发沿着 $d^{(k)}$ 进行一维搜索，找到最优步长 λ_k ，继而 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$ 。
- 信赖域法则不同，它以 $x^{(k)}$ 为中心确定一个球域，称为**信赖域**，在此域内优化目标函数的**二次逼近式**，按照一定模式求出 $x^{(k+1)}$ 。



信賴域法

■ 基本形式

- ◆ 模型选择为二次近似模型，采用函数二阶泰勒展开，即

$$f(x_k + \mathbf{p}) \approx \varphi(\mathbf{p}) = f(x_k) + \nabla f(x_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \nabla^2 f(x_k) \mathbf{p}$$

- ◆ 优化求解如下模型

$$\min \varphi_k(\mathbf{p}) = f(x_k) + \nabla f(x_k)^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \nabla^2 f(x_k) \mathbf{p}$$

$$s.t. \quad \|\mathbf{p}\| \leq r_k \quad \text{信賴域}$$



信赖域法

■ 基本形式

$$\min \varphi_k(\mathbf{p}_k) = f(x_k) + \nabla f(x_k)^T \mathbf{p}_k + \frac{1}{2} \mathbf{p}_k^T \nabla^2 f(x_k) \mathbf{p}_k$$

$$s.t. \quad \|\mathbf{p}_k\| \leq r_k$$

最优性条件

K-T条件

$$\left\{ \begin{array}{l} \nabla^2 f(x_k)^T \mathbf{p}_k + w \mathbf{p}_k = -\nabla f(x_k) \\ w(\|\mathbf{p}_k\| - r_k) = 0 \\ w \geq 0 \\ \|\mathbf{p}_k\| \leq r_k \end{array} \right.$$

r_k **充分大**

$$\mathbf{p}_k \approx -\nabla^2 f(x_k)^{-1} \nabla f(x_k)$$

接近牛顿方向

$r_k \rightarrow 0$

$$\mathbf{p}_k \approx -\frac{1}{w} \nabla f(x_k)$$

接近最速下降方向



作业

P330:

2、14(偶数)

P331:

19